

Relatório - Dataset Espiral no TensorFlow Playground

Disciplina: Data Science & IA

Especialização: Tech Lead - Cesar School

Aluno: Lucas Matos de Medeiros

email pessoal: lucas.matos.medeiros@gmail.com

email cesar: lmm5@cesar.school

Data: 12/08/2025

1. Introdução

O presente trabalho tem como objetivo analisar o comportamento e impacto dos parâmetros de uma rede neural aplicada ao dataset Espiral no TensorFlow Playground. O estudo busca compreender como diferentes configurações influenciam o desempenho do modelo, avaliando métricas como Test Loss e Test Accuracy.

2. Metodologia

Foi utilizada a configuração, adequada para resolver o dataset Espiral com baixo nível de ruído ($\leq 5\%$) e alcançar Test Loss menor que 0.1. Os parâmetros definidos foram:

- Problem type: Classification
- Use test data: ON (50/50)
- Features: x1, x2
- Hidden layers: 3 camadas com 8 neurônios cada
- Activation: tanh
- Learning rate: 0.03
- Regularization: None
- Batch size: 10
- Noise: $\leq 5\%$
- Treinamento: até estabilizar (2k–6k steps)

3. Resultados

Com a configuração acima, foi possível atingir Test Loss tipicamente abaixo de 0.06 e Test Accuracy superior a 96%. O modelo apresentou estabilidade no aprendizado e rápida convergência.

4. Discussão sobre o Impacto dos Parâmetros

4.1 Número de Camadas

O uso de 3 camadas permitiu que a rede aprendesse representações progressivamente mais complexas, necessárias para capturar o padrão não linear da

espiral. Menos camadas levariam a underfitting, enquanto camadas excessivas poderiam gerar complexidade desnecessária.

4.2 Neurônios por Camada

O uso de 8 neurônios por camada forneceu capacidade suficiente sem sobrecarregar o modelo. Poucos neurônios limitam a complexidade da fronteira de decisão; muitos neurônios podem causar overfitting.

4.3 Função de Ativação

A função de ativação tanh se mostrou ideal para este problema por ser não-linear, suave e simétrica, permitindo capturar curvas contínuas e complexas da espiral. Funções como ReLU ou sigmoid tiveram desempenho inferior neste contexto.

4.4 Learning Rate

O valor de 0.03 possibilitou convergência rápida e estável. Taxas maiores provocaram oscilações e instabilidade; menores resultaram em treinamento mais lento.

4.5 Regularização

Sem regularização, o modelo manteve boa performance devido ao baixo ruído no dataset. Com mais ruído, a ausência de regularização poderia levar ao overfitting.

5. Conclusão

O exercício demonstrou que a escolha adequada de profundidade, capacidade, função de ativação, taxa de aprendizado e regularização é determinante para o sucesso no treinamento de redes neurais. Para o dataset Espiral com baixo ruído, a configuração utilizada se mostrou eficiente, alcançando alta acurácia e baixo erro de teste.

6. Anexos



